

UNIVERSIDADE FEDERAL DE VIÇOSA

**ANÁLISE DE IMPACTO DE NOTÍCIAS NO MERCADO FINANCEIRO BRASILEIRO
COM O USO DE MODELO DE LINGUAGEM DE GRANDE ESCALA (LLM)**

Arthur Bastos Machado de Oliveira

Matrícula nº: 101598

ORIENTADOR(A): Prof. Luciano Dias de Carvalho

VIÇOSA - MG

JULHO - 2026

Arthur Bastos Machado de Oliveira

**ANÁLISE DE IMPACTO DE NOTÍCIAS NO MERCADO FINANCEIRO BRASILEIRO
COM O USO DE MODELO DE LINGUAGEM DE GRANDE ESCALA (LLM)**

Monografia apresentada ao Departamento
de Economia da Universidade Federal de
Viçosa como parte das exigências para
obtenção do título de Bacharel em
Ciências Econômicas.

APROVADA: ____ de ____ de ____.

Nome do membro da Banca

Nome do membro da Banca

Luciano Dias de Carvalho (Orientador)

VIÇOSA-MG
JUNHO 2026

As opiniões expressas neste trabalho são de exclusiva responsabilidade do(a) autor(a).

SUMÁRIO

	Página
RESUMO	iv
1. INTRODUÇÃO	1
2. REFERENCIAL TEÓRICO	3
2.1. O PARADOXO DA INFORMAÇÃO: HME VS. SENTIMENTO	4
2.2. A EVOLUÇÃO DA ANÁLISE DE TEXTO E AS LLMS EM FINANÇAS	5
2.3. EVIDÊNCIAS EMPÍRICAS NO MERCADO BRASILEIRO (B3)	6
3. METODOLOGIA	7
3.1. DADOS E AMOSTRAS	7
3.2. ANÁLISE DE SENTIMENTO COM LLM (LLAMA 3.1 8B)	8
3.3. DEFINIÇÃO DO EVENTO E JANELA TEMPORAL	13
3.4. CÁLCULO DO RETORNO ESPERADO (MARKET MODEL)	13
3.5. CÁLCULO E ACUMULAÇÃO DOS RETORNOS ANORMAIS (AR e CAR)	14
3.6. ANÁLISE COMPLEMENTAR: ACURÁCIA DIRECIONAL E REGRESSÃO LOGÍSTICA	15
3.7. ANÁLISE COMPLEMENTAR: PORTFÓLIO LONG/SHORT E ÍNDICE DE SHARPE	17
4. ANÁLISE DE RESULTADOS	19
4.1. ESTATÍSTICA DESCRITIVA	19
4.2. RESULTADOS DO ESTUDO DE EVENTOS: RETORNO ANORMAL ACUMULADO (CAR)	20
4.3. RESULTADOS: ACURÁCIA DIRECIONAL E REGRESSÃO LOGÍSTICA	23
4.4. RESULTADOS: PORTFÓLIO LONG/SHORT	26
5. CONSIDERAÇÕES FINAIS	27
REFERÊNCIAS	29
APÊNDICE A - RESULTADOS DOS TESTES DE ROBUSTEZ	31

RESUMO

OLIVEIRA, Arthur Bastos Machado de, Bel., Universidade Federal de Viçosa, junho de 2026. **Análise de Impacto de Notícias no Mercado Financeiro Brasileiro com o Uso de Modelo de Linguagem de Grande Escala (LLM)**. Orientador: Luciano Dias de Carvalho.

Este trabalho investiga a eficácia de Modelos de Linguagem de Larga Escala (LLMs) open-source na classificação de sentimento de notícias financeiras em português e sua associação com os retornos de curto prazo de ações da B3. Foram coletadas e classificadas 10.108 manchetes sobre dez das principais empresas listadas na bolsa brasileira, publicadas entre 2023 e 2024, utilizando o modelo Llama 3.1 8B Instruct em regime de inferência zero-shot. A associação entre o sentimento extraído e o comportamento dos preços foi avaliada em quatro camadas complementares de evidência: um estudo de eventos baseado no Market Model, que encontrou Retorno Anormal Acumulado médio de +0,19% para notícias positivas e -0,61% para negativas (ambos $p < 0,001$); uma análise de acurácia direcional, que obteve 54,74% de acerto contra um baseline de 51,64% (McNemar, $p = 0,0021$); uma regressão logística com efeitos fixos por empresa, na qual o sentimento manteve-se significativo (odds ratio de 1,20; $p < 0,001$) mesmo após clusterização dos erros-padrão por data; e um backtest de portfólio long/short, que produziu Índice de Sharpe de 3,80, superior aos benchmarks de mercado, ainda que qualificado por ressalvas metodológicas relativas à ausência de custos de transação. Os resultados indicam que o sentimento extraído por um LLM de escala intermediária carrega conteúdo informativo estatisticamente detectável sobre os retornos subsequentes, de magnitude economicamente modesta, contribuindo para a escassa literatura empírica sobre uso de LLMs em notícias financeiras em português.

Palavras-chave: Modelos de Linguagem de Larga Escala; Análise de Sentimento; Mercado Financeiro Brasileiro; Estudo de Eventos.

1. INTRODUÇÃO

A dinâmica dos mercados financeiros é, em sua essência, um processo contínuo de assimilação de informações. Conforme postulado pela Hipótese dos Mercados Eficientes (HME) em sua forma semi-forte (FAMA, 1970), os preços dos ativos devem refletir instantaneamente todas as informações publicamente disponíveis. Historicamente, esse mecanismo de ajuste de preços dependia da capacidade humana de interpretar notícias, relatórios de lucros, decisões de política monetária e comunicados corporativos. No entanto, o advento da era do Big Data transformou radicalmente esse cenário, gerando um volume de dados não estruturados (majoritariamente textos) que excede em muito a capacidade humana de processamento manual em tempo hábil.

Nesse contexto, a literatura financeira tem se voltado cada vez mais para métodos quantitativos capazes de extrair sinais de negociação a partir de textos. Os trabalhos seminais de Tetlock (2007) demonstraram empiricamente que o pessimismo na mídia influenciava negativamente os preços das ações e aumentava a volatilidade do mercado. Inicialmente, essas análises dependiam de técnicas rudimentares de Processamento de Linguagem Natural (PLN), como a abordagem Bag-of-Words e o uso de dicionários de polaridade, sendo o léxico desenvolvido por Loughran e McDonald (2011) o padrão-ouro na indústria. Esses autores identificaram que palavras com conotação negativa na linguagem comum (como “custo” ou “passivo”) nem sempre carregam o mesmo sentimento no jargão financeiro, exigindo listas de palavras adaptadas.

Apesar de representarem um avanço, as abordagens baseadas em dicionários e contagem de palavras apresentam limitações severas. Elas falham em capturar o contexto, a ironia, a negação complexa e as nuances semânticas que compõem a interpretação de um texto. Uma frase como “A empresa conseguiu evitar a queda de lucros esperada” seria classificada como negativa por algoritmos tradicionais devido às palavras “queda” e “evitar”, quando, na realidade, carrega um sentimento positivo de superação de expectativas.

A recente revolução na Inteligência Artificial, impulsionada pela arquitetura Transformer apresentada por Vaswani et al. (2017), permitiu o surgimento dos Modelos de Linguagem de Larga Escala (LLMs – Large Language Models).

Diferentemente de seus predecessores, modelos como o BERT (Bidirectional Encoder Representations from Transformers) e, mais recentemente, as famílias GPT (OpenAI) e Llama (Meta), possuem mecanismos de “atenção” que os permitem compreender a relação semântica entre as palavras, interpretando o texto com uma competência próxima à humana. Estudos recentes, como o de Lopez-Lira e Tang (2023), sugerem que LLMs avançados superaram significativamente os métodos tradicionais na previsão de retornos de ações baseados em manchetes de notícias, indicando uma mudança de paradigma na análise financeira automatizada.

Contudo, observa-se uma lacuna relevante na literatura empírica. A vasta maioria dos estudos concentra-se no mercado norte-americano e na língua inglesa. A aplicação dessas tecnologias em mercados emergentes, como o brasileiro, enfrenta desafios adicionais, como a escassez de datasets financeiros rotulados em português e as especificidades da volatilidade política e econômica local. Além disso, muitos estudos baseiam-se em modelos proprietários e de alto custo (como o GPT-4), havendo necessidade de validar a eficácia de modelos open-source (de código aberto), que oferecem maior transparência e reprodutibilidade científica.

O presente trabalho busca preencher essa lacuna ao investigar a seguinte questão de pesquisa: qual é a eficácia de Modelos de Linguagem de Larga Escala (LLMs) open-source na classificação de sentimento de notícias financeiras em português e qual seu impacto nos retornos de curto prazo das ações listadas na B3?

Para responder a essa questão, este estudo incorpora diferentes métodos estatísticos: a princípio, estima-se a significância estatística do Retorno Anormal Acumulado (CAR) por meio de um Estudo de Evento; análise de acurácia com um teste de McNemar e uma regressão logística com efeitos fixos por empresa; e por fim, um backtest com a construção de um portfólio long-short e cálculo do Índice de Sharpe. Foram coletadas e processadas 10.798 manchetes relacionadas a dez das principais empresas listadas na B3 entre os anos de 2023 e 2024. A classificação de sentimento foi realizada utilizando o modelo Llama 3.1 8B Instruct, instruído para atuar como um analista financeiro, e os resultados foram confrontados com os retornos anormais das respectivas ações para verificar a existência de associação estatística entre o sentimento extraído e o comportamento dos preços.

O objetivo geral consiste, portanto, em investigar a eficácia de um Modelo de Linguagem de Larga Escala (LLM) open-source na classificação de sentimento de notícias financeiras em português e avaliar sua associação com os retornos de curto

prazo de ações listadas na B3, por meio de um desenho empírico em múltiplas camadas de evidência.

O trabalho estrutura-se da seguinte forma: após esta introdução, a seção 2 apresenta o referencial teórico sobre eficiência de mercado, finanças comportamentais e a evolução do PLN em finanças. A seção 3 detalha a metodologia de coleta de dados, a arquitetura do modelo de linguagem utilizado e o modelo econométrico. A seção 4 apresenta a análise dos resultados e, por fim, a seção 5 traz as considerações finais.

2. REFERENCIAL TEÓRICO

Esta seção estabelece o embasamento teórico e as evidências empíricas que sustentam a hipótese central deste trabalho: que o sentimento extraído de notícias financeiras por Modelos de Linguagem de Larga Escala (LLMs) está associado aos retornos de ações no mercado de capitais.

2.1. O PARADOXO DA INFORMAÇÃO: HME VS. SENTIMENTO

O ponto de partida da análise de mercado é a Hipótese dos Mercados Eficientes (HME), proposta por Fama (1970). Fundamentada em pressupostos da Economia Clássica, como a racionalidade estrita dos agentes, a HME é tradicionalmente dividida em três formas, de acordo com o conjunto de informação que se presume estar refletido nos preços. Na forma fraca, os preços refletem toda a informação contida nas séries históricas de preços, tornando a análise técnica ineficaz para gerar retornos anormais consistentes. Na forma semi-forte — a relevante para este trabalho —, os preços incorporam, além do histórico de preços, toda a informação publicamente disponível, incluindo demonstrações financeiras, notícias e comunicados corporativos, de modo que nenhum agente conseguiria obter retorno anormal sistemático processando informação já pública. Na forma forte, os preços refletiriam até mesmo informação privilegiada (*insider information*), hipótese cuja violação é amplamente documentada e não é objeto deste estudo.

É importante notar, seguindo Fama (1991) e a literatura subsequente, que todo teste empírico da HME é necessariamente um teste conjunto: rejeitar a hipótese nula de que os preços refletem toda a informação disponível é indissociável de rejeitar (ou não) o modelo de precificação de ativos utilizado para definir o que seria o retorno "normal". No caso deste trabalho, o Market Model (seção 3.4). Um

retorno anormal estatisticamente significativo pode, em princípio, refletir tanto uma ineficiência informacional genuína quanto uma má especificação do modelo de retorno esperado. Esse é um dos motivos pelos quais a literatura de estudos de eventos trata os resultados como evidência de associação entre o evento e o retorno, e não como prova definitiva de ineficiência de mercado.

Períodos de alta volatilidade ao longo da década de 80 evidenciaram importantes limitações à HME, como demonstrado por Shiller (2003), a partir das quais emergiu a Teoria das Finanças Comportamentais (Thaler; Kahneman & Tversky), que argumenta que o comportamento dos agentes econômicos é guiado por vieses cognitivos e emocionais, resultando em reações exageradas (overreaction) ou insuficientes (underreaction) a eventos noticiosos.

Complementarmente, a literatura de noise trader models (De Long et al., 1990) e de limites à arbitragem (Shleifer; Vishny, 1997) oferece um mecanismo teórico para que ineficiências de precificação persistam mesmo na presença de agentes racionais: arbitrar um desvio de preço exige capital, tempo e disposição a assumir risco, de modo que agentes racionais podem preferir não corrigir integralmente um erro de precificação causado por investidores com vieses comportamentais, sobretudo em horizontes curtos como o estudado aqui (janela de dois dias). Nesse cenário, o sentimento do investidor, frequentemente capturado pelo tom da mídia, torna-se uma variável fundamental para explicar o movimento dos preços. A existência de retornos anormais após a divulgação de notícias (o post-earnings-announcement drift ou post-event drift) consistentes e estatisticamente significativos é uma das principais evidências de ineficiência, justificando a busca por fatores preditivos além dos fundamentos. Como será discutido na seção 4, a magnitude assimétrica dos retornos anormais associados a notícias positivas e negativas encontrada neste estudo é, em si, coerente com essa literatura de reação assimétrica e com o mecanismo de aversão à perda (loss aversion) proposto por Kahneman e Tversky (1979).

2.2. A EVOLUÇÃO DA ANÁLISE DE TEXTO E AS LLMS EM FINANÇAS

A tentativa de quantificar o sentimento da mídia evoluiu em três etapas principais:

2.2.1. Dicionários e contagem de palavras (era pré-LLM)

O trabalho seminal de Loughran e McDonald (2011) transformou a análise textual em finanças ao criar um léxico específico, ajustando palavras comuns para o contexto financeiro. O estudo de Tetlock (2007), que correlacionou o pessimismo da mídia com a queda de preços, utilizou a análise de texto como proxy para o sentimento. Esses métodos, embora eficientes, possuem a limitação crítica de serem cegos ao contexto. Não conseguem distinguir o impacto positivo de “evitar uma queda de lucros” do impacto negativo de “queda de lucros”, apenas pela contagem das palavras.

2.2.2. Modelos contextuais e LLMs

A limitação contextual foi superada pelo surgimento de modelos baseados na arquitetura Transformer (VASWANI et al., 2017). LLMs como BERT, GPT e, mais recentemente, Llama, utilizam mecanismos de “atenção” para entender a dependência e o significado das palavras dentro da frase. A literatura empírica global demonstra a superioridade preditiva dessas arquiteturas. O estudo de Kirtac e Germano (2024), ao comparar LLMs (como OPT, BERT e Llama 3) com o modelo de dicionário Loughran-McDonald em 965 mil artigos de notícias financeiras, encontrou que o modelo OPT superou significativamente os demais, alcançando uma acurácia de previsão de direção de retorno de 74,4%, e que uma estratégia de portfólio long-short baseada em seus scores atingiu um Sharpe ratio de 3,05, comparado a 1,23 para a estratégia baseada em dicionário.

Em direção semelhante, Lopez-Lira e Tang (2023) documentaram que o GPT-4, ao classificar manchetes de notícias como positivas, negativas ou neutras para a empresa correspondente, atinge taxas de acerto (hit rates) de aproximadamente 90% na identificação da direção da reação inicial do mercado, e que a capacidade de avaliação financeira aumenta com o tamanho do modelo — modelos mais simples, como Llama 2-7b, exibem capacidade preditiva limitada quando comparados a modelos de maior escala. Essa evidência é particularmente relevante para o presente estudo, que emprega um modelo de escala intermediária (Llama 3.1 8B), e será retomada na discussão dos resultados da seção 4.

Essas evidências corroboram a eficácia do uso de LLMs para a tarefa específica de classificação de sentimento associada a retornos, ao mesmo tempo em que sugerem que a magnitude dessa eficácia é sensível à escala do modelo empregado.

2.2.3. LLMs em documentos complexos

Além das notícias curtas, LLMs provaram ser eficazes na sumarização de documentos extensos. O trabalho de Gupta (2023) demonstra o valor dos LLMs na análise de Relatórios Anuais de empresas, que chegam a mais de 100 páginas, utilizando features geradas por LLMs em um modelo de Machine Learning para quant trading e obtendo desempenho superior ao do S&P 500 no período analisado. Essa evidência reforça o potencial do LLM como uma ferramenta de extração de valor de textos financeiros de diferentes naturezas e extensões.

2.3. EVIDÊNCIAS EMPÍRICAS NO MERCADO BRASILEIRO (B3)

A aplicação da análise textual na B3 é mais escassa, mas igualmente relevante. Dias e Malaquias (2021), utilizando a metodologia de estudo de eventos sobre uma amostra de 83 empresas brasileiras e 236 notícias entre 2012 e 2019, identificaram que a divulgação de notícias relacionadas a possível envolvimento em corrupção gera retorno anormal negativo e estatisticamente significativo, principalmente na data de divulgação, evidenciando que eventos de natureza não estritamente financeira (como escândalos éticos) têm efeito relevante sobre o valor de mercado das empresas listadas na B3. Padula e Albuquerque (2018) também encontraram uma relação negativa e significativa entre a divulgação de informações relacionadas à corrupção governamental e a valorização de empresas estatais no mercado de capitais brasileiro.

Esses dois trabalhos compartilham com o presente estudo a mesma estrutura metodológica de base — o estudo de eventos com Market Model de fator único — ainda que classifiquem o evento de interesse de forma binária e manual (presença ou ausência de notícia de corrupção), e não por meio de um modelo de linguagem aplicado a um fluxo amplo de notícias de natureza diversa. A magnitude dos retornos anormais negativos por eles reportados serve, na seção 4, como parâmetro de comparação para avaliar a plausibilidade dos efeitos aqui estimados.

A necessidade de testar o Llama 3.1 no contexto brasileiro se baseia na premissa de que a eficácia dos modelos de linguagem pode variar de acordo com o idioma, o domínio específico (notícias financeiras) e a estrutura do mercado, justificando o foco no cálculo do Retorno Anormal (AR) para ativos da B3.

3. METODOLOGIA

A metodologia escolhida para a análise do impacto das notícias nos preços dos ativos foi o estudo de eventos. Esse método tem como objetivo estimar o impacto de um evento sobre uma variável por meio do cálculo da diferença entre os retornos esperados e os observados após a ocorrência do fenômeno.

3.1. DADOS E AMOSTRAS

Foram coletados dados relacionados a 10 das maiores empresas da bolsa de valores brasileira. A construção da amostra foi segmentada em duas fontes principais: dados textuais (notícias) e dados financeiros (cotações).

O recorte 2023–2024 corresponde a um período de transição macroeconômica e política relevante para a interpretação dos resultados. Trata-se de um período marcado pelo retorno à “normalidade” dos mercados após o choque da pandemia de Covid-19, e sua relativa estabilização ao longo de 2022. O início de 2023 marcou a mudança de governo federal, com reflexos diretos sobre empresas estatais ou de forte interligação com a política econômica. Em especial a Petrobras, cuja política de preços de combustíveis e de distribuição de dividendos foi objeto de reformulações e de intensa cobertura jornalística ao longo do período, e o Banco do Brasil, cuja governança e estratégia de crédito também estiveram sob escrutínio público. O período coincide, ainda, com um ciclo de política monetária contracionista seguido de flexibilização: a taxa SELIC, que serve neste trabalho como proxy do ativo livre de risco, permaneceu em patamar elevado ao longo de 2023 e iniciou trajetória de cortes a partir do segundo semestre, o que afeta o custo de capital e a atratividade relativa de setores sensíveis a juros, como o bancário (Bradesco, Banco do Brasil, Itaú, BTG Pactual, Itaúsa) e o de consumo (Ambev).

A seleção das dez empresas obedeceu a quatro critérios conjuntos. Primeiro, representatividade no índice de mercado: todas as empresas selecionadas figuram entre as de maior peso no Ibovespa ao longo do período analisado, o que assegura que a proxy de mercado utilizada no Market Model (o próprio Ibovespa) tem relação direta e relevante com os ativos estudados, evitando o uso de um benchmark pouco correlacionado aos papéis de interesse. Segundo, liquidez: as dez ações apresentam volume médio diário de negociação elevado e presença constante no pregão, condição necessária para que os preços ajustados reflitam informação de

mercado tempestiva e para que o cálculo de retornos diários não seja distorcido por iliquidez ou por preços desatualizados. Terceiro, diversificação setorial: a amostra cobre petróleo e gás (Petrobras), setor bancário e financeiro (Bradesco, Banco do Brasil, Itaú, BTG Pactual, Itaúsa), bens de consumo (Ambev), utilidade pública/energia elétrica (Eletrobras), mineração (Vale) e bens de capital/indústria (WEG), reduzindo a chance de que os resultados sejam artefato de um único setor da economia. Quarto, volume mínimo de cobertura jornalística: empresas com pouca presença na mídia inviabilizariam a aplicação das quatro camadas de teste propostas, em especial a regressão logística e o backtest de portfólio, que dependem de um número mínimo de eventos por ativo para gerar inferência estatística com poder adequado. Critério que, ao mesmo tempo, explica por que empresas menores ou de menor cobertura midiática, ainda que relevantes na bolsa, não foram incluídas nesta primeira aplicação da metodologia.

Esses critérios implicam, como contrapartida reconhecida, a concentração da amostra em empresas de grande porte e alta visibilidade midiática (seção 4.2.2), mas asseguram a viabilidade estatística do desenho em quatro camadas e a comparabilidade com a proxy de mercado utilizada.

A Eletrobras, por sua vez, encontrava-se em processo de consolidação societária após sua privatização, concluída em 2022, o que manteve a empresa sob acompanhamento constante do mercado quanto a mudanças de governança e de estrutura de capital. A Vale seguia sob monitoramento relacionado a passivos ambientais e a preços internacionais de minério de ferro, enquanto a WEG, única representante do setor industrial de bens de capital na amostra, refletia principalmente notícias operacionais e de resultados, com volume de cobertura substancialmente menor que o das demais.

Do ponto de vista da validade externa dos resultados, é relevante notar que o período não inclui choques sistêmicos de grande magnitude, como os observados durante a pandemia de Covid-19, o que favorece a interpretação de que os efeitos aqui estimados refletem a dinâmica "normal" de precificação de notícias corporativas e não a resposta do mercado a um evento macroeconômico extremo. Por outro lado, a concentração da cobertura jornalística em torno de Petrobras, Bradesco e Banco do Brasil (seção 3.1.1) está parcialmente associada a esse contexto de maior exposição política e regulatória dessas três empresas no período, o que é retomado como limitação na seção 4.2.2.

3.1.1. Coleta de dados textuais (notícias)

A amostra de notícias foi coletada via RSS Feeds indexados pelo Google News, utilizando a biblioteca pygooglenews (Python). O período de coleta abrange 24 meses, de 01 de janeiro de 2023 a 31 de dezembro de 2024.

Para maximizar a relevância e evitar ruídos (ex.: manchetes com a palavra “Vale” não relacionada à mineradora), utilizou-se uma estratégia de busca booleana (OR), focando a pesquisa em termos que aparecem no título (intitle:). Foram encontradas 10.798 notícias relevantes, concentradas nas empresas Petrobras, Bradesco e Banco do Brasil, que compõem quase 62% de toda a amostra, como descrito no Quadro 1. As principais fontes das notícias estão descritas no Quadro 2.

Quadro 1: Palavras-chave e número de notícias por empresa

Ticker	Palavras-chave	Volume Total	% do Total
PETR4	Petrobras, PETR4, PETR3	2.398	22,21
BBDC4	Bradesco, BBDC4, Banco do Brasil	2.260	20,93
BBAS3	Banco do Brasil, BBAS3	2.034	18,84
ABEV3	Ambev, ABEV3	964	8,93
ELET3	Eletrobras, ELET3, ELET6	934	8,65
BPAC11	BTG Pactual, BPAC11, Banco BTG	636	5,89
ITUB4	Itaú Unibanco, ITUB4, Banco Itaú	627	5,81
VALE3	Vale S.A., VALE3, Vale mineradora	620	5,74
WEGE3	WEGE3, WEG Motores, Empresa WEG	188	1,74
ITSA4	Itaúsa, ITSA4	137	1,27
Total	—	10.798	100,00

Fonte: Dados da pesquisa.

Quadro 2: 10 Principais Fontes de Notícias

Fonte	Contagem
InfoMoney	691
Estadão E-Investidor	686
Money Times	332
suno.com.br	326
CNN Brasil	295
O Globo	261
Agência Brasil	252
Exame	234

Valor Econômico	220
Seu Dinheiro	209
Total (10 principais)	3.506

Fonte: Dados da pesquisa.

O Quadro 3 apresenta exemplos reais de manchetes efetivamente classificadas pelo pipeline descrito na seção 3.2, selecionadas por proximidade ao CAR médio de seu respectivo grupo de sentimento (Tabela 2, seção 4.2), de modo a ilustrar o caso típico da amostra, e não seus casos de magnitude extrema.

Quadro 3: Exemplos de manchetes classificadas pela LLM e retorno anormal acumulado associado

Empresa	Manchete (título original)	Sentimento (LLM)	CAR[T0, T+1]
BBAS3	Banco do Brasil registra lucro de 8,6 bi no 1º trimestre — Seu Crédito Digital	POSITIVO	+0,19%
ITUB4	Lucro do Itaú Unibanco no trimestre cresce 14,6% para R\$ 8,43 bilhões — Safra	POSITIVO	+0,23%
PETR4	Petrobras (PETR4) lucra R\$ 26,6 bilhões no 3º trimestre, queda de 42,2% no ano e abaixo do consenso — InfoMoney	NEGATIVO	-0,58%
BBDC4	Pix do Bradesco fora do ar: usuários relatam instabilidade no aplicativo — TechTudo	NEGATIVO	-0,61%
BBAS3	Banco do Brasil passa a patrocinar o SLS Championship Tour — Marcas pelo Mundo	NEUTRO	-0,02%
ITUB4	Itaú (ITUB4) propõe incorporação do Hipercard e convoca Assembleia Extraordinária — suno.com.br	NEUTRO	+0,00%

Fonte: Dados da pesquisa

O Quadro 3 ilustra, com casos concretos, o padrão examinado estatisticamente na seção 4.2: manchetes de conteúdo claramente positivo ou negativo antecedem retornos anormais na direção correspondente, enquanto manchetes de caráter informativo ou operacional — como convocações societárias ou patrocínios — são predominantemente classificadas como neutras e associadas a CAR próximo de zero.

3.1.2. Coleta de dados financeiros (cotações)

Os dados financeiros de suporte, necessários para calcular os retornos e o benchmark, foram obtidos de duas fontes:

Cotações de Ativos e Índice: as séries históricas diárias dos preços ajustados (Adj Close) das 10 empresas e do índice de mercado Ibovespa (^BVSP)

foram extraídas via API da plataforma Yahoo Finance (yfinance). Esta fonte é amplamente aceita em pesquisas empíricas devido à sua confiabilidade e à inclusão de ajustes automáticos por proventos (dividendos, JCP). Cabe registrar que a Eletrobras alterou seu código de negociação de ELET3 para AXIA3 ao final de 2025; os preços históricos do período de 2023–2024 utilizados neste estudo foram obtidos sob o símbolo atual, que a Yahoo Finance mantém vinculado à série histórica integral do ativo, preservando a correspondência com as notícias coletadas sob a denominação anterior (ELET3).

Ativo Livre de Risco: a proxy para o retorno livre de risco no Brasil foi a Taxa SELIC Diária (Taxa CDI), obtida a partir da API do Sistema Gerenciador de Séries (SGS) do Banco Central do Brasil (código 12). Esta taxa é fundamental para o cálculo dos retornos em excesso no Market Model (Equação 1).

3.2. ANÁLISE DE SENTIMENTO COM LLM (LLAMA 3.1 8B)

A classificação do sentimento das 10.798 manchetes foi realizada utilizando um Modelo de Linguagem de Larga Escala (LLM), adotando a abordagem de inferência e classificação sem treinamento supervisionado (zero-shot learning).

3.2.1. Arquitetura e infraestrutura de inferência

O modelo selecionado foi o Meta Llama 3.1 8B Instruct (8 bilhões de parâmetros). Essa escolha é justificada pela sua performance em tarefas de raciocínio e obediência a instruções (característica da versão Instruct) e por se tratar de um modelo de pesos abertos (open-source), de menor custo computacional do que modelos proprietários como o GPT-4, atendendo diretamente à questão de pesquisa proposta na seção 1.

A inferência foi executada por meio da API da Groq, provedora especializada em hospedar modelos de linguagem de pesos abertos em hardware próprio (LPU – Language Processing Unit), otimizado para inferência de alta vazão. A API da Groq é compatível com a especificação da API da OpenAI, o que permitiu a integração do pipeline de classificação por meio de uma biblioteca cliente padrão de mercado. Importa destacar que o uso de uma API de inferência hospedada não compromete a natureza open-source do experimento: os pesos do modelo permanecem os mesmos publicamente disponibilizados pela Meta, sendo a Groq responsável

apenas pela camada de hospedagem e execução, de forma análoga ao uso de uma instância de nuvem com GPU dedicada.

3.2.2. Estratégia de prompt engineering e processamento em lote

Em vez de treinar o modelo para a tarefa específica (o que seria fine-tuning), optou-se pela estratégia de Prompt Engineering, definindo a persona, o contexto e o formato de saída desejado. Isso transforma o LLM em um classificador de texto com conhecimento de domínio financeiro. A inferência foi configurada para ser determinística (parâmetro temperature=0), o que reduz a aleatoriedade na resposta e tende a fazer com que a mesma manchete gere o mesmo resultado de sentimento em execuções repetidas.

Por restrições de limite de requisições (rate limiting) impostas pelo provedor de API, a classificação foi implementada com processamento em lote: cada requisição submeteu um conjunto de 15 manchetes simultaneamente, com o modelo retornando um vetor de classificações na mesma ordem de entrada, em formato JSON. O Quadro 3 ilustra a estrutura lógica do prompt utilizado para cada manchete individual dentro do lote.

Quadro 4: Estrutura de Prompt para Classificação de Sentimento (Llama 3.1 8B)

Componente	Conteúdo	Função
System Role	“Você é um analista financeiro experiente especializado em mercado brasileiro (B3).”	Define a persona e o domínio de conhecimento.
User Content	Manchete: “{titulo}” sobre a empresa {empresa}.	Injeta o dado bruto e o contexto de negociação.
Restrição	“Responda apenas com um array JSON contendo, na mesma ordem, uma das etiquetas: POSITIVO, NEGATIVO ou NEUTRO, sem explicação.”	Força a saída estruturada exigida pelo pipeline de processamento.

Fonte: Elaborado pelo autor.

3.2.3. Codificação da variável sentimento

A variável de saída do modelo é categórica, assumindo três valores possíveis: POSITIVO, NEUTRO ou NEGATIVO. Para fins de análise estatística, essa variável foi codificada numericamente como: 1 se positivo; 0 se neutro (manchetes sem impacto claro); -1 se negativo. Essa codificação permite que a variável Sentimento (S) seja utilizada diretamente nos testes de associação com o Retorno Anormal Acumulado (CAR), apresentados na seção 4.

3.2.4. Tratamento de falhas de classificação

Do total de 10.798 manchetes submetidas ao modelo, 690 (6,4% da amostra) não puderam ser classificadas após sucessivas tentativas de reprocessamento, em razão de falhas de formatação na resposta retornada pela API (por exemplo, respostas que não constituíam um array JSON válido ou que continham número de elementos diferente do esperado). Verificou-se que essas falhas se distribuíram de forma proporcional entre as dez empresas e ao longo de todo o período de coleta, sem concentração identificável em nenhum ticker ou intervalo de datas específico, o que reduz a probabilidade de viés sistemático decorrente da exclusão. Essas observações foram removidas da amostra sem substituição, resultando em uma amostra analítica final de 10.108 manchetes classificadas, utilizada em toda a análise apresentada na seção 4.

3.3. DEFINIÇÃO DO EVENTO E JANELA TEMPORAL

O evento (T_0) é definido como a data de publicação da manchete, classificada pela LLM. Para garantir a pertinência dos dados, os eventos são mapeados da seguinte forma: publicações durante o pregão (9h30 às 17h00) têm seu impacto mensurado no próprio dia e no dia útil seguinte; publicações após o fechamento ou em fim de semana têm seu impacto mensurado a partir do primeiro dia útil subsequente. Verificou-se, na prática, que mais de 97% das manchetes da amostra carregam horário de publicação padronizado pelo agregador de RSS (entre 4h e 5h no horário de Brasília), anterior à abertura do pregão — o que simplifica a regra de mapeamento, fazendo com que a esmagadora maioria dos eventos siga o segundo critério.

A análise foi dividida nas seguintes janelas, seguindo os procedimentos descritos por MacKinlay (1997) e detalhados em Miller (2023): Janela de Estimação (L_1): período entre 120 e 30 dias úteis anteriores ao evento, utilizada para estimar os parâmetros α e β do Market Model sem contaminação pelo próprio evento; Janela de Evento (L_2): período de dois dias — a data do evento (T_0) e o dia útil seguinte ($T+1$) — utilizada para observar o efeito imediato da notícia.

3.4. CÁLCULO DO RETORNO ESPERADO (MARKET MODEL)

Para isolar o efeito da notícia do movimento geral do mercado, estima-se o retorno que seria esperado da ação na ausência do evento. Utiliza-se o Market Model, uma simplificação do CAPM que incorpora o ativo livre de risco.

3.4.1. Estimação dos parâmetros

Os parâmetros da relação linear entre o retorno em excesso do ativo e o retorno em excesso do mercado são estimados por meio de uma regressão OLS (Ordinary Least Squares), utilizando os dados da Janela de Estimação:

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_i(R_{m,t} - R_{f,t}) + \varepsilon_{i,t} \quad (1)$$

Onde:

$R_{i,t}$: retorno do ativo i no dia t .

$R_{f,t}$: retorno da taxa livre de risco (CDI) no dia t .

$R_{m,t}$: retorno do Ibovespa no dia t (proxy de mercado).

$\varepsilon_{i,t}$: resíduo (erro) do modelo.

α_i : intercepto — retorno do ativo não explicado pelo mercado.

β_i : coeficiente de sensibilidade (risco sistemático) do ativo i em relação ao mercado.

3.5. CÁLCULO E ACUMULAÇÃO DOS RETORNOS ANORMAIS (AR e CAR)

3.5.1. Retorno esperado

Após estimar os coeficientes $\hat{\alpha}_i$ e $\hat{\beta}_i$ na Janela de Estimação, o Retorno Esperado para os dias dentro da Janela de Evento é calculado como:

$$E[R_{i,t}] = \hat{\alpha}_i + R_{f,t} + \hat{\beta}_i(R_{m,t} - R_{f,t}) \quad (2)$$

3.5.2. Retorno anormal (AR)

O Retorno Anormal é a diferença entre o retorno efetivamente observado e o retorno esperado com base na relação histórica entre o ativo e o mercado:

$$AR_{i,t} = R_{i,t} - E[R_{i,t}] \quad (3)$$

3.5.3. Retorno anormal acumulado (CAR)

Para mensurar o efeito total da notícia ao longo da Janela de Evento, calcula-se o Retorno Anormal Acumulado:

$$CAR_i(T_0, T_{+1}) = AR_{i,T_0} + AR_{i,T_{+1}} \quad (4)$$

Onde T_0 e $T+1$ definem a Janela de Evento utilizada neste estudo, conforme estabelecido na seção 3.3.

3.5.4. Teste estatístico e significância

O teste de hipótese central deste estudo compara o CAR médio entre os grupos de notícias classificadas como positivas, neutras e negativas, formalizado como:

Hipótese Nula (H_0): o retorno anormal acumulado médio do grupo é igual a zero ($\bar{CAR} = 0$).

Hipótese Alternativa (H_1): o retorno anormal acumulado médio do grupo é diferente de zero ($\bar{CAR} \neq 0$).

A significância é testada por meio do Teste-t de média para uma amostra, verificando se o CAR médio de cada grupo de sentimento é estatisticamente diferente de zero, complementado por um teste-t unilateral para verificar se o CAR médio do grupo de notícias positivas é estatisticamente maior do que o CAR médio do grupo de notícias negativas.

3.6. ANÁLISE COMPLEMENTAR: ACURÁCIA DIRECIONAL E REGRESSÃO LOGÍSTICA

Para além do teste de diferença de médias apresentado na seção 3.5.4 — que avalia a associação entre sentimento e magnitude do retorno anormal —, conduziu-se uma análise complementar voltada à capacidade preditiva direcional do modelo, nos moldes empregados por Lopez-Lira e Tang (2023) e Kirtac e Germano (2024).

3.6.1. Reformulação binária e acurácia direcional

Para essa análise, as observações classificadas como NEUTRO foram excluídas, uma vez que uma classificação neutra não constitui, por definição, uma previsão de direção — procedimento análogo ao adotado por Lopez-Lira e Tang (2023), que tratam separadamente as classificações “Yes/No” das “Unsure” em sua metodologia. Definiu-se a variável binária $Y=1$ se $CAR[T_0, T+1]>0$ e $Y=0$ em caso contrário, e a previsão do modelo $\hat{Y}=1$ se o sentimento da notícia for POSITIVO e $\hat{Y}=0$ se NEGATIVO. A acurácia direcional é, então:

$$\text{Acurácia} = (\text{nº de previsões corretas}) / (\text{nº total de previsões}) \quad (5)$$

Para que a acurácia obtida tenha valor interpretativo, ela é comparada a um baseline justo, definido como a proporção da classe majoritária observada na amostra (e não 50% de forma arbitrária):

$$\text{Baseline} = \max(\% \text{ CAR} > 0, \% \text{ CAR} \leq 0) \quad (6)$$

3.6.2. Teste de McNemar

Para verificar se a diferença entre a acurácia do modelo e o baseline é estatisticamente significativa, e não fruto de variação amostral, aplicou-se o teste de McNemar (MCNEMAR, 1947), apropriado para a comparação de dois classificadores avaliados sobre a mesma amostra. O teste considera apenas os casos em que os dois classificadores divergem: seja b o número de casos em que somente o modelo acerta, e c o número de casos em que somente o baseline acerta. A estatística do teste é dada por:

$$\chi^2 = (|b - c| - 1)^2 / (b + c) \quad (7)$$

que segue, sob a hipótese nula de equivalência entre os classificadores, uma distribuição qui-quadrado com 1 grau de liberdade.

3.6.3. Matriz de confusão

De forma complementar, a matriz de confusão detalha a distribuição dos acertos e erros do modelo entre as categorias previstas (positivo/negativo) e observadas (CAR positivo/não positivo), permitindo identificar eventuais assimetrias sistemáticas na direção dos erros de classificação.

3.6.4. Regressão logística com efeitos fixos por empresa

Por fim, estimou-se um modelo de regressão logística para investigar, de forma mais refinada do que a acurácia bruta, a relação entre o sentimento e a probabilidade de retorno anormal positivo, controlando-se por heterogeneidade não observada entre empresas por meio de efeitos fixos:

$$P(\text{CAR} > 0) = 1 / (1 + e^{-(\beta_0 + \beta_1 \cdot S + \sum \gamma_j \cdot \text{Empresa}_j)}) \quad (8)$$

Onde S é a variável de sentimento (codificada -1 ou $+1$, conforme seção 3.2.3) e γ_j representa o efeito fixo da empresa j (sendo uma categoria de referência omitida por identificação do modelo). O coeficiente β_1 é o parâmetro de interesse,

interpretado por meio do odds ratio e^{β_1} : o fator multiplicativo na chance (odds) de retorno anormal positivo associado a uma notícia positiva, mantida fixa a empresa.

O ajuste do modelo é avaliado pelo Pseudo R^2 de McFadden, métrica análoga ao R^2 da regressão linear, porém adequada a modelos de variável dependente binária.

Para a estrutura de covariância dos erros, adotou-se clusterização por data de publicação. A clusterização simultânea por data e por empresa (double clustering, conforme Kirtac e Germano, 2024) seria a abordagem mais geral, pois endereça tanto a correlação entre observações de diferentes empresas no mesmo dia quanto a correlação entre observações da mesma empresa em datas distintas. Contudo, a validade assintótica dos erros-padrão clusterizados exige que o número de grupos seja suficientemente grande — Cameron e Miller (2015) apontam $G \geq 50$ como referência mínima. Com apenas 10 empresas na amostra, a clusterização por firma produziria erros-padrão subestimados em vez de conservadores, comprometendo a robustez da inferência. A clusterização por data, por sua vez, conta com aproximadamente 500 grupos distintos no período analisado, atendendo plenamente ao requisito assintótico e corrigindo o principal canal de dependência entre observações: choques de mercado comuns a múltiplas empresas no mesmo dia. Testes de especificação funcional (link test) não evidenciaram má especificação da forma logística adotada ($p=0,11$).

3.7. ANÁLISE COMPLEMENTAR: PORTFÓLIO LONG/SHORT E ÍNDICE DE SHARPE

Como exercício adicional de significância econômica — e não apenas estatística — do sinal extraído pela LLM, replicou-se, em escala reduzida, a metodologia de backtest de portfólio empregada por Kirtac e Germano (2024).

3.7.1. Construção do portfólio

Para cada dia útil em que houve ao menos uma notícia não neutra sobre alguma das dez empresas, construiu-se uma posição comprada (long) nas ações cujo sentimento agregado do dia foi positivo e uma posição vendida (short) nas ações cujo sentimento agregado foi negativo — sendo o sentimento agregado, quando mais de uma notícia da mesma empresa ocorre no mesmo dia, definido pela

média da variável S nesse dia. O retorno diário do portfólio long/short, financeiramente neutro (dólar-neutro), foi aproximado por:

$$R_{\text{portfólio}} = (CAR_{\text{long}} - CAR_{\text{short}}) / 2 \quad (9)$$

Cabe destacar uma simplificação metodológica relevante: o retorno de cada posição é aproximado pelo $CAR[T0, T+1]$ já calculado no estudo de eventos (seção 3.5.3), atribuindo-se à data do sinal a totalidade do retorno de dois dias — procedimento usual em backtests acadêmicos baseados em eventos, mas que não corresponde a uma simulação estrita de carteira com rebalanceamento diário contínuo. Adicionalmente, o exercício não incorpora custos de transação, custos de aluguel de ações para as posições vendidas, nem restrições de liquidez — limitações retomadas na discussão dos resultados na seção 4.4.

3.7.2. Índice de Sharpe e erro-padrão

O desempenho ajustado ao risco da estratégia foi avaliado pelo Índice de Sharpe anualizado:

$$Sharpe = (\bar{R}_{\text{portfólio}} / \sigma_{\text{portfólio}}) \times \sqrt{252} \quad (10)$$

Dado que a estimativa do Índice de Sharpe está sujeita a erro amostral, calculou-se seu erro-padrão pela aproximação i.i.d. de Lo (2002):

$$SE(Sharpe) \approx \sqrt{((1 + 0,5 \cdot Sharpe^2) / T)} \quad (11)$$

onde T é o número de dias com posição aberta. Essa estimativa de erro-padrão pressupõe retornos independentes e identicamente distribuídos, premissa que pode subestimar a incerteza real caso haja autocorrelação decorrente da sobreposição entre janelas de eventos de datas próximas — ressalva incorporada à interpretação dos resultados na seção 4.4.

O desempenho da estratégia foi comparado a dois benchmarks: a carteira buy-and-hold do Ibovespa e uma cesta igual-ponderada (equal-weighted) das dez ações da amostra, ambos calculados sobre o mesmo período e com a mesma metodologia de Índice de Sharpe.

4. ANÁLISE DE RESULTADOS

4.1. ESTATÍSTICA DESCRITIVA

Das 10.108 manchetes que compõem a amostra analítica final (conforme tratamento descrito na seção 3.2.4), a classificação produzida pelo Llama 3.1 8B distribuiu-se entre as três categorias de sentimento conforme apresentado na Tabela 1.

Tabela 1: Distribuição das notícias por sentimento classificado pela LLM

Sentimento	N	% do Total
NEUTRO	4.889	48,37
POSITIVO	2.738	27,09
NEGATIVO	2.481	24,55
Total	10.108	100,00

Fonte: Dados da pesquisa.

Observa-se uma predominância de notícias classificadas como neutras (48,4%), seguidas por positivas (27,1%) e negativas (24,5%). Essa distribuição é consistente com a natureza do fluxo de notícias coletado via Google News, que inclui grande volume de comunicados institucionais, divulgações operacionais e menções factuais sem conteúdo de sentimento claro — e não apenas eventos de mercado com forte carga valorativa.

Para todas as 10.108 observações foi possível calcular o Retorno Anormal Acumulado (CAR), uma vez que a totalidade dos eventos dispunha de, no mínimo, 30 dias úteis de dados na Janela de Estimação, conforme exigido pela metodologia descrita na seção 3.4.

Para todas as 10.108 observações foi possível calcular o Retorno Anormal Acumulado (CAR), uma vez que a totalidade dos eventos dispunha de, no mínimo, 30 dias úteis de dados na Janela de Estimação, conforme exigido pela metodologia descrita na seção 3.4.

A Figura 1 complementa a Tabela 2 (seção 4.2) ao apresentar a distribuição completa do $CAR[T_0, T+1]$ em cada grupo de sentimento, e não apenas suas médias. A mediana do CAR é próxima de zero nos três grupos, mas a caixa do grupo NEGATIVO está deslocada para baixo em relação à do grupo POSITIVO, e sua dispersão é a maior entre os três — consistente com o maior desvio-padrão

reportado na Tabela 2 (2,97% no grupo NEGATIVO, ante 2,38% no POSITIVO e 2,20% no NEUTRO) e com a assimetria discutida na seção 4.2.




Figura 1: Distribuição do CAR[T0, T+1] por grupo de sentimento

Fonte: Dados da pesquisa

4.2. RESULTADOS DO ESTUDO DE EVENTOS: RETORNO ANORMAL ACUMULADO (CAR)

A Tabela 2 apresenta os resultados do teste de hipótese formulado na seção 3.5.4, comparando o CAR[T0, T+1] médio entre os três grupos de sentimento.

Tabela 2: Resultados do teste de hipótese — CAR[T0, T+1] por grupo de sentimento

Sentimento	N	CAR médio (%)	Desvio padrão (%)	Estatística t	p-valor	IC 95%
POSITIVO	2.738	+0,1854	2,3766	4,0827	<0,001***	[+0,0964; +0,2745]
NEUTRO	4.889	-0,0162	2,2020	-0,5144	0,607	[-0,0779; +0,0455]
NEGATIVO	2.481	-0,6078	2,9697	-10,1950	<0,001***	[-0,7247; -0,4909]

Nota: *** $p < 0,01$. Teste-t de média para uma amostra ($H_0: \bar{CAR} = 0$). Fonte: Dados da pesquisa.

Como análise de robustez, estimou-se uma regressão OLS do CAR sobre as dummies de sentimento com erros-padrão clusterizados por data, controlando a

potencial dependência cross-seccional entre retornos anormais de eventos simultâneos. Os coeficientes permaneceram estatisticamente significativos (NEGATIVO: $z=-3,17$, $p=0,002$; POSITIVO vs. NEGATIVO: $z=4,35$, $p<0,001$), confirmando que as conclusões da seção 4.2 são robustas à presença de correlação intragrupo dentro de cada data de evento.

Os resultados confirmam, de forma estatisticamente robusta, a hipótese central deste trabalho. O CAR médio do grupo de notícias POSITIVAS (+0,19%) e do grupo NEGATIVAS (-0,61%) são ambos significativamente diferentes de zero ao nível de 1%, ao passo que o grupo NEUTRO (-0,02%) não apresenta diferença estatisticamente significativa em relação a zero ($p=0,607$) — comportamento esperado de um grupo de controle adequadamente calibrado, que reforça a validade da classificação produzida pela LLM.

O teste-t unilateral comparando diretamente os dois grupos extremos confirma que o CAR médio das notícias positivas é estatisticamente maior do que o das negativas ($t=10,6988$; $p<0,001$).

Um achado que merece destaque é a assimetria de magnitude entre os dois efeitos: o CAR médio do grupo NEGATIVO (-0,61%) é aproximadamente 3,3 vezes maior, em valor absoluto, do que o CAR médio do grupo POSITIVO (+0,19%). Essa assimetria é coerente com a literatura de Finanças Comportamentais discutida na seção 2.1, segundo a qual investidores tendem a reagir de forma mais intensa a perdas potenciais do que a ganhos de magnitude equivalente (aversão à perda), sugerindo que o mercado brasileiro processa notícias negativas sobre as empresas estudadas com maior intensidade do que notícias positivas de teor comparável.

Os resultados encontrados também são compatíveis, em ordem de grandeza, com os retornos anormais negativos reportados por Dias e Malaquias (2021) para eventos de corrupção na B3 (CAR médio de -2,29% na janela de 5 dias) — ainda que a comparação direta seja limitada pela diferença de natureza dos eventos (notícias de corrupção versus fluxo geral de notícias) e de janela temporal.

4.2.1. Resultados por empresa

A Tabela 3 desagrega o CAR médio por empresa e grupo de sentimento, permitindo avaliar a heterogeneidade do efeito estimado entre os dez ativos da amostra.

Tabela 3: CAR médio por empresa e grupo de sentimento

Ticker	Sentimento	N	CAR médio (%)
ABEV3	NEGATIVO	167	-1,0366
ABEV3	NEUTRO	468	-0,3433
ABEV3	POSITIVO	179	-0,3078
BBAS3	NEGATIVO	385	-0,1345
BBAS3	NEUTRO	1.212	+0,1361
BBAS3	POSITIVO	407	-0,0215
BBDC4	NEGATIVO	625	-0,9769
BBDC4	NEUTRO	1.048	+0,0109
BBDC4	POSITIVO	542	-0,1359
BPAC11	NEGATIVO	81	+0,0537
BPAC11	NEUTRO	252	-0,0398
BPAC11	POSITIVO	273	+0,0519
ELET3	NEGATIVO	277	-0,2843
ELET3	NEUTRO	336	+0,2212
ELET3	POSITIVO	246	+0,1109
ITSA4	NEGATIVO	27	+0,0528
ITSA4	NEUTRO	43	-0,4177
ITSA4	POSITIVO	52	+0,1264
ITUB4	NEGATIVO	101	-0,0865
ITUB4	NEUTRO	289	+0,0400
ITUB4	POSITIVO	177	+0,5299
PETR4	NEGATIVO	641	-0,7727
PETR4	NEUTRO	959	-0,1253
PETR4	POSITIVO	603	+0,4187
VALE3	NEGATIVO	155	-0,2836
VALE3	NEUTRO	212	-0,0675
VALE3	POSITIVO	163	+0,7194
WEGE3	NEGATIVO	22	-2,3470
WEGE3	NEUTRO	70	-0,2629
WEGE3	POSITIVO	96	+1,3926

Fonte: Dados da pesquisa.

A desagregação revela heterogeneidade relevante entre os ativos. A WEGE3 apresenta os efeitos de maior magnitude em ambas as direções (+1,39% para notícias positivas e -2,35% para negativas), embora a reduzida quantidade de eventos negativos para esse ativo (N=22) recomende cautela na generalização

desse resultado específico. Já a BPAC11 apresenta CAR médio próximo de zero em ambas as direções, sugerindo que o mercado precifica rapidamente as notícias relacionadas a essa instituição, ou que o conteúdo informativo das notícias coletadas sobre ela é, em média, menos relevante.

Um resultado que destoa do padrão geral é o da ABEV3, cujo grupo de notícias POSITIVAS está associado a um CAR médio negativo ($-0,31\%$). Esse padrão pode ser consistente com um efeito de “sell the news”, em que a informação positiva já havia sido antecipada e precificada pelo mercado antes de sua divulgação formal, ou pode refletir ruído amostral dado o N moderado (179) desse subgrupo. Esse achado é retomado na discussão da seção 4.3 para os fins deste trabalho, à luz dos efeitos fixos por empresa estimados na regressão logística.

4.2.2. Limitações da análise de estudo de eventos

Três limitações metodológicas devem ser reconhecidas na interpretação dos resultados desta seção. Primeiramente, a amostra de notícias apresenta concentração relevante em apenas três das dez empresas (Petrobras, Bradesco e Banco do Brasil, que juntas representam 62% do total), de modo que o efeito agregado encontrado na Tabela 2 pode estar parcialmente influenciado pelo comportamento específico desses três ativos, ainda que a desagregação por empresa na Tabela 3 mitigue parcialmente essa preocupação ao demonstrar que o sinal do efeito é qualitativamente consistente entre a maioria dos ativos.

Em segundo lugar, a unidade textual classificada pela LLM foi a manchete da notícia, e não o corpo integral do texto, o que privilegia velocidade e custo de processamento em detrimento de eventual perda de nuance presente no conteúdo completo da reportagem.

Por fim, quando mais de uma notícia sobre a mesma empresa é publicada no mesmo dia útil, todas elas são associadas ao mesmo valor de CAR diário, mesmo que apresentem sentimentos diferentes entre si. Esse procedimento, necessário diante da granularidade diária dos dados de preço, tende a introduzir ruído na relação entre sentimento e retorno, na medida em que múltiplos sinais potencialmente conflitantes do mesmo dia são comprimidos em uma única observação de retorno.

4.3. RESULTADOS: ACURÁCIA DIRECIONAL E REGRESSÃO LOGÍSTICA

Excluídas as observações classificadas como NEUTRO (conforme critério estabelecido na seção 3.6.1), a amostra utilizada nesta seção totaliza 5.219 notícias. O baseline da classe majoritária (proporção de CAR>0 na amostra) corresponde a 51,64%, ao passo que a acurácia direcional do Llama 3.1 8B foi de 54,74% — uma melhora de 3,1 pontos percentuais sobre o baseline.

O teste de McNemar confirma que essa diferença não é atribuível a variação amostral ($\chi^2=9,4671$; $p=0,0021$), evidenciando que o sinal extraído pelo modelo carrega informação direcional estatisticamente detectável, ainda que de magnitude modesta em termos absolutos.

Tabela 4: Matriz de confusão — previsão direcional do modelo

	Real: CAR>0	Real: CAR≤0
Previsto Positivo	1.450	1.288
Previsto Negativo	1.074	1.407

Fonte: Dados da pesquisa.

A matriz de confusão não revela viés grosseiro de classificação em nenhuma das direções, com erros razoavelmente distribuídos entre falsos positivos e falsos negativos.

A Tabela 5 apresenta os resultados da regressão logística com efeitos fixos por empresa (Equação 8), tomando a ABEV3 como categoria de referência (omitida por exigência de identificação do modelo, dado que efeitos fixos categóricos exigem a exclusão de um nível como base de comparação).

Tabela 5: Regressão logística — P(CAR>0) em função do sentimento e de efeitos fixos por empresa

Variável	Coeficiente	Erro-padrão	z	p-valor
Intercepto (ABEV3)	−0,4445	0,225	−1,975	0,048**
BBAS3	+0,3680	0,252	1,461	0,144
BBDC4	+0,2268	0,259	0,875	0,381
BPAC11	+0,5494	0,307	1,789	0,074*
ELET3	+0,3976	0,281	1,417	0,156
ITSA4	+0,4624	0,461	1,002	0,316
ITUB4	+0,4229	0,308	1,374	0,170
PETR4	+0,4372	0,266	1,646	0,100*
VALE3	+0,6563	0,278	2,364	0,018**

WEGE3	+0,4993	0,365	1,368	0,171
Sentimento (S)	+0,1844	0,040	4,608	<0,001***

Nota: N=5.219. Pseudo R² (McFadden)=0,0107. Log-Likelihood=-3.575,9. Erros-padrão clusterizados por data *p<0,10; **p<0,05; ***p<0,01. Categoria de referência: ABEV3. Fonte: Dados da pesquisa.

O coeficiente da variável de sentimento mantém-se positivo e estatisticamente significativo após a clusterização dos erros-padrão por data ($z=4,608$; $p<0,001$), correspondendo a um odds ratio de 1,2025: uma notícia positiva multiplica por 1,20 a chance (odds) de retorno anormal positivo, mantida fixa a empresa. A comparação com os erros-padrão sem clusterização ($SE=0,028$ vs. $SE=0,040$ com cluster, aumento de 43%) evidencia que a dependência cross-seccional entre eventos simultâneos de fato existe e infla a precisão aparente dos estimadores, mas não é suficiente para comprometer a significância do parâmetro de interesse.

Os efeitos fixos por empresa perderam em grande parte a significância individual sob a especificação com clustering, com exceção da VALE3 ($p=0,018$) e da PETR4 e BPAC11 na fronteira de 10%. Esse padrão é esperado: choques de mercado comuns dentro de cada data de evento introduzem correlação entre os erros de observações de empresas distintas no mesmo dia, inflacionando os erros-padrão dos coeficientes de empresa de forma mais pronunciada do que o do coeficiente de sentimento, que varia de forma mais independente entre datas. A perda de significância dos efeitos fixos não altera a interpretação do parâmetro de interesse nem compromete a função de controle que esses efeitos exercem no modelo.

O Pseudo R² de 0,0107, embora baixo em termos absolutos, é compatível com a natureza ruidosa dos retornos financeiros diários e com magnitudes reportadas na literatura para problemas similares. O ABEV3, ao apresentar a menor probabilidade-base de retorno anormal positivo entre as dez empresas (intercepto = -0,4445), confirma a anomalia identificada na seção 4.2.1, em que o grupo de notícias positivas dessa empresa esteve associado a CAR médio negativo.

Comparativamente à literatura internacional, a acurácia direcional aqui encontrada (54,74%) é substancialmente inferior às taxas de acerto reportadas por Lopez-Lira e Tang (2023) para o GPT-4 (aproximadamente 90% para a reação inicial) e à acurácia de 74,4% reportada por Kirtac e Germano (2024) para o modelo OPT. Essa diferença é compatível com o achado central de Lopez-Lira e Tang (2023) de que a capacidade de avaliação financeira é uma capacidade emergente que

aumenta com a escala do modelo: o Llama 3.1 8B utilizado neste estudo é substancialmente menor do que o GPT-4 e do que os modelos fine-tunados empregados por Kirtac e Germano (2024), o que torna o resultado modesto, porém ainda assim estatisticamente robusto, coerente com as expectativas teóricas da literatura.

4.4. RESULTADOS: PORTFÓLIO LONG/SHORT

A estratégia de portfólio long/short descrita na seção 3.7 produziu posição em 499 dias úteis dentro do período analisado. A Tabela 6 compara o desempenho ajustado ao risco da estratégia com os dois benchmarks definidos na metodologia.

Tabela 6: Índice de Sharpe — estratégia long/short versus benchmarks

Estratégia	Sharpe	Erro-padrão (Lo, 2002)	N dias
Long/Short (sinal LLM)	3,7961	0,7207	499
Ibovespa (buy-and-hold)	0,3724	—	667
Cesta 10 ações (buy-and-hold)	0,8221	—	667

Fonte: Dados da pesquisa.

O retorno médio diário da estratégia foi de 0,2665%, resultando em um Índice de Sharpe anualizado de 3,80 (IC 95% aproximado: [2,38; 5,21]), substancialmente superior aos dois benchmarks (Ibovespa: 0,37; cesta igual-ponderada: 0,82) e na mesma ordem de grandeza do Sharpe de 3,05 reportado por Kirtac e Germano (2024) para o mercado norte-americano com o modelo OPT.

Esse resultado, contudo, deve ser interpretado com cautela considerável, por quatro razões. Primeiro, o backtest não incorpora custos de transação nem custos de aluguel de ações para as posições vendidas, ambos relevantes no contexto do mercado brasileiro. Segundo, a diversificação cross-seccional inerente à construção do portfólio (médias diárias entre múltiplos ativos) tende a reduzir mecanicamente a variância dos retornos do portfólio, inflacionando o Índice de Sharpe estimado — um artefato conhecido em backtests acadêmicos dessa natureza. Terceiro, o erro-padrão de Lo (2002) utilizado pressupõe retornos independentes e identicamente distribuídos; como há sobreposição temporal entre janelas de eventos de empresas e datas próximas, é provável que a incerteza real associada à estimativa do Sharpe seja maior do que a reportada na Tabela 6. Quarto, e mais fundamentalmente, a simplificação descrita na seção 3.7.1 — atribuir à data do sinal

a totalidade do retorno de dois dias — não corresponde a uma simulação estrita de execução de carteira.

Por esses motivos, o resultado da Tabela 6 deve ser lido como evidência de que o sinal extraído pela LLM carrega conteúdo economicamente relevante em um ambiente de backtest sem fricções, e não como uma estimativa do retorno ajustado ao risco realizável em condições efetivas de negociação no mercado brasileiro.

5. CONSIDERAÇÕES FINAIS

O presente trabalho investigou a eficácia de um Modelo de Linguagem de Larga Escala open-source (Llama 3.1 8B Instruct) na classificação de sentimento de notícias financeiras em português e seu impacto nos retornos de curto prazo de dez das principais ações listadas na B3, entre 2023 e 2024. A investigação foi conduzida em quatro camadas complementares de evidência, de complexidade crescente, cujos resultados convergem para uma mesma conclusão geral: o sentimento extraído pela LLM carrega conteúdo informativo estatisticamente detectável sobre os retornos subsequentes das ações analisadas, ainda que de magnitude economicamente modesta.

Na primeira camada, o estudo de eventos clássico (seção 4.2) encontrou retornos anormais acumulados estatisticamente diferentes de zero para os grupos de notícias positivas (+0,19%; $p < 0,001$) e negativas (−0,61%; $p < 0,001$), com o grupo neutro funcionando adequadamente como controle ($p = 0,607$). A assimetria de magnitude entre os efeitos positivo e negativo — o efeito negativo é cerca de 3,3 vezes maior — é consistente com a literatura de aversão à perda revisada na seção 2.1.

Na segunda camada, a reformulação do problema como classificação direcional binária (seção 4.3) encontrou acurácia de 54,74% frente a um baseline justo de 51,64%, diferença estatisticamente significativa pelo teste de McNemar ($p = 0,0021$) e corroborada por uma regressão logística com efeitos fixos por empresa, na qual o sentimento manteve-se significativo (odds ratio de 1,20; $p < 0,001$) mesmo controlando-se a heterogeneidade entre ativos. A magnitude modesta desse resultado, frente às acurácias substancialmente maiores reportadas por Lopez-Lira e Tang (2023) e Kirtac e Germano (2024) para modelos de maior

escala, é compatível com a tese desses autores de que a capacidade de raciocínio financeiro é uma capacidade emergente que cresce com o tamanho do modelo.

Na terceira camada, o backtest de portfólio long/short (seção 4.4) produziu um Índice de Sharpe de 3,80, superior aos benchmarks de mercado considerados, sinalizando relevância econômica potencial do sinal extraído — resultado que, no entanto, foi qualificado por ressalvas metodológicas substanciais relativas à ausência de custos de transação, à inflação do Sharpe por diversificação cross-seccional e à possível subestimação do erro-padrão pela presença de autocorrelação não capturada pela aproximação de Lo (2002).

Em conjunto, essas evidências contribuem para a escassa literatura empírica sobre o uso de LLMs aplicados a notícias financeiras em português, estendendo ao contexto brasileiro evidências documentadas majoritariamente para o mercado norte-americano, e dialogam com a literatura nacional de estudos de eventos aplicados a notícias corporativas (DIAS; MALAQUIAS, 2021; PADULA; ALBUQUERQUE, 2018).

As limitações deste estudo — detalhadas nas seções 4.2.2, 3.6 e 3.7.1 — incluem a concentração da amostra de notícias em três das dez empresas analisadas, a granularidade da classificação ao nível da manchete, a agregação de múltiplas notícias do mesmo dia em um único valor de retorno, e as simplificações inerentes ao backtest de portfólio sem fricções de mercado. Sugere-se, para pesquisas futuras: (i) a extensão da classificação ao texto completo das reportagens; (ii) a comparação sistemática de desempenho entre modelos de diferentes escalas no contexto brasileiro, nos moldes de Lopez-Lira e Tang (2023); (iii) a incorporação de custos de transação e de aluguel de ações ao backtest de portfólio; e (iv) a ampliação da amostra de empresas para reduzir o desbalanceamento setorial identificado na coleta de notícias.

REFERÊNCIAS

- Cameron, A. C., Miller, D. L. (2015). A Practitioner's Guide to Cluster-Robust Inference. **Journal of Human Resources**, 50(2), 317–372.
- DE LONG, J. B.; SHLEIFER, A.; SUMMERS, L. H.; WALDMANN, R. J. Noise Trader Risk in Financial Markets. **Journal of Political Economy**, v. 98, n. 4, p. 703-738, 1990.
- DIAS, B.; MALAQUIAS, R. Corrupção e retorno de ações de empresas listadas na B3. **Brazilian Review of Finance (Online)**, Rio de Janeiro, v. 19, p. 123-150, 2021.
- FAMA, E. F. Efficient capital markets: a review of theory and empirical work. **The Journal of Finance**, v. 25, n. 2, p. 383-417, 1970.
- FAMA, E. F. Efficient Capital Markets: II. **The Journal of Finance**, v. 46, n. 5, p. 1575-1617, 1991.
- GUPTA, U. GPT-InvestAR: enhancing stock investment strategies through annual report analysis with Large Language Models. 2023. Disponível em: <<https://arxiv.org/abs/2309.03079>>. Acesso em: 12 jun. 2026.
- KAHNEMAN, D.; TVERSKY, A. Prospect Theory: An Analysis of Decision under Risk. **Econometrica**, v. 47, n. 2, p. 263-292, 1979.
- KIRTAC, K.; GERMANO, G. Enhanced financial sentiment analysis and trading strategy development using Large Language Models. In: WORKSHOP ON COMPUTATIONAL APPROACHES TO SUBJECTIVITY, SENTIMENT, & SOCIAL MEDIA ANALYSIS, 14., 2024. **Anais [...]**. p. 1-10.
- LO, A. W. The statistics of Sharpe ratios. **Financial Analysts Journal**, v. 58, n. 4, p. 36-52, 2002.
- LOPEZ-LIRA, A.; TANG, Y. Can ChatGPT forecast stock price movements? Return predictability and Large Language Models. **SSRN Electronic Journal**, 2023.
- LOUGHRAN, T.; MCDONALD, B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. **The Journal of Finance**, v. 66, n. 1, p. 35-65, 2011.
- MACKINLAY, A. C. Event studies in economics and finance. **Journal of Economic Literature**, v. 35, n. 1, p. 13-39, 1997.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. **Psychometrika**, v. 12, n. 2, p. 153-157, 1947.
- MILLER, D. An introductory guide to event study models. **Journal of Economic Perspectives**, v. 37, n. 2, p. 203-230, 2023.
- PADULA, A.; ALBUQUERQUE, P. H. M. Corrupção governamental no mercado de capitais: um estudo acerca da Operação Lava Jato. **RAE – Revista de Administração de Empresas**, FGV EAESP, v. 58, n. 4, p. 405-417, 2018.

SHILLER, R. J. From Efficient Markets Theory to Behavioral Finance. **Journal of Economic Perspectives**, v. 17, n. 1, p. 83-104, 2003.

SHLEIFER, A.; VISHNY, R. W. The Limits of Arbitrage. **The Journal of Finance**, v. 52, n. 1, p. 35-55, 1997.

TETLOCK, P. C. Giving content to investor sentiment: the role of media in the stock market. **The Journal of Finance**, v. 62, n. 3, p. 1139-1168, 2007.

VASWANI, A. et al. Attention is all you need. **Advances in Neural Information Processing Systems**, v. 30, 2017.

APÊNDICE A – RESULTADOS DOS TESTES DE ROBUSTEZ

A.1 Teste de Dependência Cross-Seccional e Regressão OLS com Erros Clusterizados por Data

Para avaliar a existência de dependência cross-seccional entre os retornos anormais acumulados (CAR) de eventos simultâneos, calculou-se a covariância par a par dos CARs de notícias publicadas no mesmo dia. Foram identificados 115.356 pares de eventos simultâneos, com covariância média de 0,000367 (t-stat = 50,76): estatisticamente significativa porém economicamente negligenciável. Como análise de robustez complementar, estimou-se uma regressão OLS do CAR sobre as dummies de sentimento com erros-padrão clusterizados por data (conforme justificado na seção 3.6.4). Os resultados estão apresentados na Tabela A.1.

Tabela 1.A: Regressão OLS — CAR em função do sentimento (erros-padrão clusterizados por data)

Variável	Coefficiente	Erro-padrão	z	p-valor
Intercepto (NEGATIVO)	-0,0061	0,002	-3,169	0,002**
NEUTRO	+0,0059	0,001	4,004	<0,001***
POSITIVO	+0,0079	0,002	4,351	<0,001***

Nota: N=10.108. $R^2=0,014$. Categoria de referência: NEGATIVO. Erros-padrão clusterizados por data. **p<0,05; ***p<0,01. Fonte: Dados da pesquisa.

Os coeficientes são estatisticamente significativos após a clusterização (NEGATIVO: $z=-3,17$, $p=0,002$; POSITIVO vs. NEGATIVO: $z=4,35$, $p<0,001$), confirmando que as conclusões da seção 4.2 são robustas à dependência cross-seccional. Os CAR médios implícitos: NEGATIVO=-0,61%; NEUTRO=-0,02%; POSITIVO=+0,18% — idênticos às médias da Tabela 2.

A.2 Regressão Logística sem Clusterização dos Erros-Padrão (especificação original)

Para fins de comparação com a especificação adotada na seção 4.3, apresenta-se a regressão logística sem clusterização dos erros-padrão. A

comparação permite quantificar o efeito da dependência cross-seccional sobre a precisão aparente dos estimadores.

Tabela 2.A: Regressão logística — $P(CAR > 0)$ sem clusterização dos erros-padrão

Variável	Coefficiente	Erro-padrão	z	p-valor
Intercepto (ABEV3)	-0,4445	0,111	-4,022	<0,001***
BBAS3	+0,3680	0,132	2,797	0,005***
BBDC4	+0,2268	0,125	1,809	0,070*
BPAC11	+0,5494	0,155	3,556	<0,001***
ELET3	+0,3976	0,141	2,816	0,005***
ITSA4	+0,4624	0,252	1,837	0,066*
ITUB4	+0,4229	0,164	2,585	0,010**
PETR4	+0,4372	0,124	3,516	<0,001***
VALE3	+0,6563	0,158	4,147	<0,001***
WEGE3	+0,4993	0,216	2,308	0,021**
Sentimento (S)	+0,1844	0,028	6,488	<0,001***

Nota: N=5.219. Pseudo R^2 (McFadden)=0,0107. Log-Likelihood=-3.575,9. Erros-padrão não clusterizados (MLE padrão). * $p < 0,10$; ** $p < 0,05$; *** $p < 0,01$. Categoria de referência: ABEV3. Fonte: Dados da pesquisa.

O erro-padrão do coeficiente de sentimento aumentou de 0,028 (sem cluster) para 0,040 com clusterização por data (+43%), com a estatística z reduzindo de 6,488 para 4,608. Os efeitos fixos por empresa tiveram seus erros-padrão inflados pela clusterização, refletindo a correlação intra-data entre observações de empresas distintas. Em ambas as especificações, o coeficiente de sentimento permanece altamente significativo ($p < 0,001$), confirmando a robustez do resultado principal da seção 4.3.